

# ACTIVIDAD DE APRENDIZAJE #1

JOSE DAVID CARDONA MAZO

Proyecto Integrado III - Analítica de Datos (**Sharon Karin Camacho**) -  
PREICA2502B020071

## UNIVERSIDAD DIGITAL DE ANTIOQUIA – 2025

### Definición del problema

Se necesita evaluar y analizar de manera cuantitativa cual es la influencia de las variables meteorológicas tales como: temperatura, precipitación, velocidad del viento, radiación solar y humedad relativa en la concentración y variabilidad de los contaminantes atmosféricos (PM10, PM2.5, NO<sub>2</sub>, SO<sub>2</sub>, CO y O<sub>3</sub>) que son registrados desde las estaciones de monitoreo de calidad del aire de Colombia. El propósito esta investigación y análisis es identificar patrones de correlación y cuáles son esas tendencias temporales que nos permitan predecir todas aquellas posibles excedencias de los límites establecidos por la normativa ambiental, así podríamos contribuir a la toma de decisiones basadas en evidencia en la gestión ambiental y por sobre todo en la protección de la salud pública.

### Hipótesis

Las condiciones meteorológicas influyen de manera significativa en los niveles de contaminación atmosférica.

En particular evaluaremos las siguientes relaciones:

- Incrementos en la **temperatura** y la **radiación solar** se asocian con mayores concentraciones de ozono (O<sub>3</sub>).
- Bajos niveles de **precipitación** y **humedad relativa** favorecen la acumulación de partículas PM10 y PM2.5.
- Mayores velocidades de **viento** tienden a reducir la concentración de contaminantes debido a la dispersión atmosférica.

Estas relaciones permitirán construir **modelos predictivos medibles** basados en coeficientes de correlación (R<sup>2</sup>), precisión del modelo (RMSE) y número de días que cuenten con excedencias de los límites de calidad del aire.

### Granularidad

La granularidad del análisis que se realizará **será horaria y por estación de monitoreo**, ya que eso nos va a permitir observar todas esas variaciones temporales y espaciales en las concentraciones de contaminantes. Este nivel de detalle es relevante desde mi punto de vista porque facilita la identificación de patrones, correlaciones y eventos críticos de contaminación por lo que después en un futuro podremos mejorar la precisión de los modelos predictivos y se harán la toma de decisiones ambientales.

### Diccionario de datos

Columna	Descripción	Tipo de Dato	Ejemplo
<b>id_estacion</b>	Identificador único asignado a la estación de monitoreo.	Numérico	20383
<b>autoridad_ambiental</b>	Autoridad ambiental encargada de la estación.	Texto	CORANTIOQUIA
<b>estacion</b>	Nombre de la estación de monitoreo.	Texto	ALTAVISTA
<b>latitud</b>	Coordenada geográfica que indica la latitud de la estación.	Numérico	6.222.584
<b>longitud</b>	Coordenada geográfica que indica la longitud de la estación.	Numérico	-75.628.207
<b>variable</b>	Contaminante o variable meteorológica medida en la estación (PM10, PM2.5, temperatura, etc.).	Texto	PM10
<b>unidades</b>	Unidad de medida para la variable.	Texto	ug/m3
<b>tiempo_de_exposicion_horas</b>	Horas de exposición durante el monitoreo.	Numérico	1
<b>a_o</b>	Año en el que se realizaron las mediciones.	Numérico	2011
<b>promedio</b>	Promedio anual de la medición de la variable (contaminante o meteorológica).	Numérico	75.5
<b>suma</b>	Total acumulado anual de la medición de la variable.	Numérico	329454.0
<b>no_de_datos</b>	Número total de datos válidos recopilados en ese año de medición.	Numérico	4363
<b>representatividad_temporal</b>	Porcentaje del tiempo que tiene datos válidos registrados.	Categórico	50%
<b>excedencias_limite_actual</b>	Número de veces que el contaminante ha superado el límite permitido en ese año.	Numérico	0
<b>porcentaje_excedencias_limite</b>	Porcentaje de veces que se superó el límite permitido durante el año.	Numérico	0.0%
<b>mediana</b>	Mediana de la medición del contaminante durante el año.	Numérico	64.0
<b>percentil_98</b>	Percentil 98 de la medición del contaminante durante el año (valor por debajo del cual está el 98% de los datos).	Numérico	208.0
<b>maximo</b>	Valor máximo de la medición durante el año.	Numérico	524.0
<b>fechas_horas_del_maximo</b>	Fecha y hora del valor máximo registrado durante el año.	Fecha/Tiempo	27/10/2011 8:00:00 p. m.
<b>minimo</b>	Valor mínimo de la medición durante el año.	Numérico	7.0

<b>fechas_horas_del_minimo</b>	Fecha y hora del valor mínimo registrado durante el año.	Fecha/Tiempo	27/10/2011 8:00:00 p. m.
<b>dias_de_excedencias</b>	Número de días en que se superó el límite permitido.	Numérico	0
<b>codigo_del_departamento</b>	Código DANE del departamento donde se encuentra la estación.	Numérico	5
<b>nombre_del_departamento</b>	Nombre del departamento.	Texto	ANTIOQUIA
<b>codigo_del_municipio</b>	Código DANE del municipio donde se encuentra la estación.	Numérico	5001
<b>nombre_del_municipio</b>	Nombre del municipio.	Texto	MEDELLÍN
<b>tipo_de_estacion</b>	Tipo de estación de monitoreo (fija o móvil).	Texto	Fija
<b>ubicacion</b>	Información geoespacial de la estación (coordenadas en formato JSON).	Geoespacial	{'type': 'Point', 'coordinates': [- 75.628207, 6.222584]}

### Posibles problemas en cada aspecto analizado en la exploración

- **Datos faltantes (nulos):** Se evidenció la presencia de valores nulos en columnas y variables, esto puede afectar el análisis y la correlación de las variables:
- **Inconsistencia en formatos de fecha y hora:** algunos de los formatos no están adecuados para su agrupación correcta lo que nos puede generar conflictos al momento de comparar.
- **Duplicados:** Existe gran cantidad de duplicados
- **Inconsistencias geográficas:** Algunas estaciones presentan coordenadas nulas o ubicaciones fuera del rango de Colombia, lo que afectará de alguna manera la representación espacial y el mapeo geográfico de los datos.
- **Valores atípicos, raros o extremos:** Existen valores atípicos dentro de los datos lo que nos puede decir que puede deberse a un sensor malo o que surgieron errores en la captura de esos datos

### Conclusiones

- Tenemos una fuente de datos muy útil y que nos permitirá llevar a cabo el análisis correcto, se requiere de una gran limpieza para asegurar confiabilidad.
- Se identifican tendencias y valores claros, con respecto a la contaminación en zonas urbanas o industriales con respecto a la comparativa con zonas rurales.
- Los datos meteorológicos que tenemos en el dataset presentan una variabilidad que desde mi perspectiva es suficiente para construir modelos de correlación y predicción.

## **Tareas específicas para la limpieza de datos**

- Se normalizarán formatos de fecha y hora.
- Se eliminarán los valores nulos y duplicados.
- Se filtrará con los valores atípicos para corregirlos usando percentiles.
- Se validan coordenadas de estaciones dentro del rango geográfico de Colombia.

## **ENLACE A GITHUB**

<https://github.com/josedav-17/analiticaDeDatos3.git>

## **ENLACE A TRELLO**

<https://trello.com/invite/b/6911115e4d2b851c2700433f/ATTI558c5564fca7516329b39ce7a443fbed99E1B4C2/analiticadedatos3>

## **ENLACE DEL DATASET**

<datos.gov.co/resource/kek-d-7v7h.json?>