

ACTIVIDAD DE APRENDIZAJE #2

JOSE DAVID CARDONA MAZO

Proyecto Integrado III - Analítica de Datos

PREICA2502B020071

Sharon Karin Camacho

UNIVERSIDAD DIGITAL DE ANTIOQUIA – 2025

DESARROLLO

¿Cómo se relacionan las variables meteorológicas con los niveles de contaminación del aire y en qué medida pueden utilizarse para anticipar posibles excedencias de los límites ambientales en Colombia?

En el análisis exploratorio de los datos nos encontramos con varios temas y puntos que efectivamente no permitirían que respondiéramos nuestra pregunta inicial con lo cual procedimos a realizar la respectiva revisión y gestión en los datos, donde evidenciamos que cada fila representa un evento de medición individual que se realiza para una estación de monitoreo y/o un contaminante determinado. Lo que nos indica que se presenta una **granularidad alta** en los datos, evidenciamos que para una misma estación y contaminante pueden existir múltiples registros dentro del mismo año, lo que refleja datos de tipo horario o de períodos cortos.

Esto nos permite abordar la pregunta y llevarla a lo que queríamos pudiendo en un futuro resolver el interrogante que hoy, digamos cambio un poco porque en ese proceso me di cuenta que podemos ir más allá y lograr responderla en el futuro.

Descripción de Necesidades de Limpieza y limpieza realizada.

1- Valores duplicados:

Nos encontramos con los siguientes resultados en el momento de realizar la limpieza de datos.

```
FILAS INICIALES: 28732
FILAS FINALES: 8699
FILAS ELIMINADAS POR DUPLICADOS EXACTOS: 0
FILAS ELIMINADAS POR DUPLICADOS LOGICOS: 20033
FILAS ELIMINADAS POR FALTA DE UBICACION: 0
```

Quiero aclarar que esta validación de duplicados la realicé por valores lógicos y valores en las filas completas duplicadas, esto con el fin de poder observar una granularidad en los datos, donde luego del análisis y la limpieza correcta podemos afirmar que:

- **Existían varias observaciones para una misma estación, variable y año.**
- **Se garantizó una única fila por combinación lógica.**
- **No se encontraron filas con datos duplicados.**

2- VALORES NULOS

Para el análisis de valores nulos encontramos lo siguiente:

```
NULOS INICIALES VS IMPUTADOS:  
Representatividad Temporal -> antes: 62 despues: 0  
Excedencias limite actual -> nulos antes convert: 0 despues: 0  
Nombre del Municipio -> antes: 0 despues: 0  
Tipo de Estacion -> antes: 0 despues: 0  
Codigo del Municipio -> antes: 2 despues: 0
```

Siendo las columnas de Representatividad Temporal y Código del Municipio aquellas columnas que tenían valores nulos y estos fueron tratados con mediante imputación para no afectar los análisis.

3- INCONSISTENCIAS EN VALORES

En este punto se realizó primeramente la normalización de las columnas, comas, tildes, puntos y demás en los datos para que se pudiese realizar un mejor análisis en los datos.

4- VALORES ATÍPICOS

Aquí Se detectaron valores extremos en promedio, máximos, mínimos y días de excedencias.

```
OUTLIERS RECORTADOS POR COLUMNA:  
Promedio: 1271 valores recortados  
Maximo: 1057 valores recortados  
Minimo: 863 valores recortados  
Días de excedencias: 1712 valores recortados  
Porcentaje excedencias limite actual: 1959 valores recortados
```

ENLACE A GITHUB:

<https://github.com/josedav-17/analiticaDeDatos3.git>

ENLACE A TRELLO:

<https://trello.com/invite/b/6911115e4d2b851c2700433f/ATTI558c5564fca7516329b39ce7a443fbed99E1B4C2/analiticadedatos3>

ENLACE DEL DATASET:

[datos.gov.co/resource/kek-d-7v7h.json?](https://datos.gov.co/resource/kek-d-7v7h.json)